

# Análise exploratória de dados

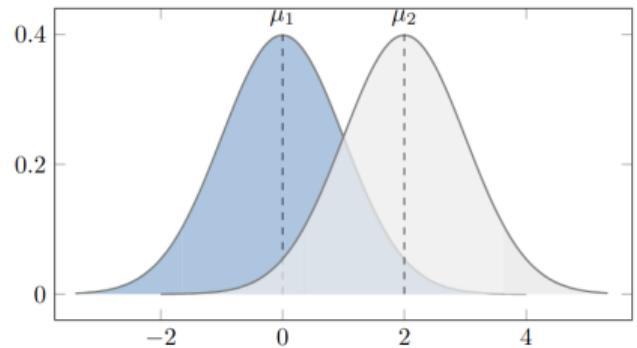
Parte 6

Prof.: Eduardo Vargas Ferreira

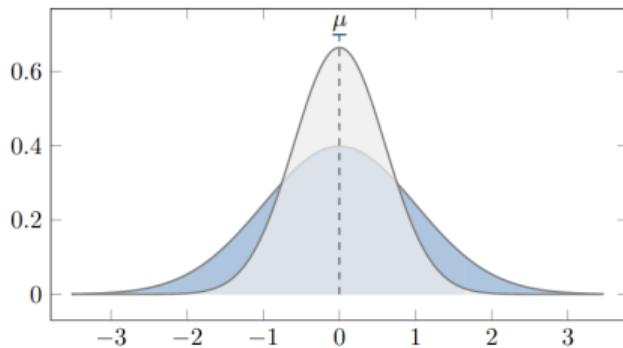


# Medidas de posição e dispersão

Medidas de posição



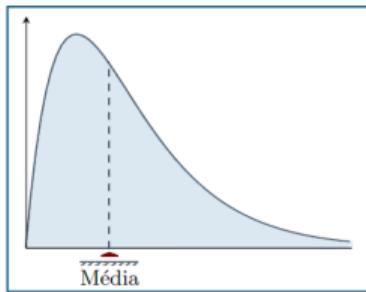
Medidas de dispersão



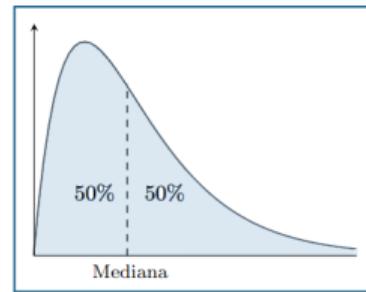
# Medidas de Posição

- As medidas de posição (ou localização) são assim denominadas por indicarem um ponto em torno do qual se concentram os dados, p. ex.;

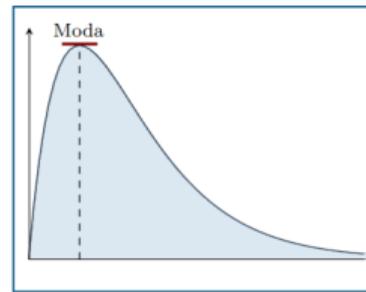
**Média aritmética (Me)**



**Mediana (Md)**



**Moda (Mo)**



Quando usamos um só valor, obtemos uma redução drástica dos dados!

# Média Aritmética

# Média Aritmética

- A **média aritmética** é a soma de todos os valores observados, dividido pelo total de observações.  
Considere as quantidades de sódio (mg) em 20 cereais matinais. Encontre a média dos dados.



0	70	125	125
140	150	170	170
180	195	205	210
210	220	220	230
250	260	290	290

$$\bar{x} = \frac{0 + 70 + 125 + \dots + 290 + 290}{20}$$
$$= 185.5$$

## Exemplo: acidentes no mês de janeiro

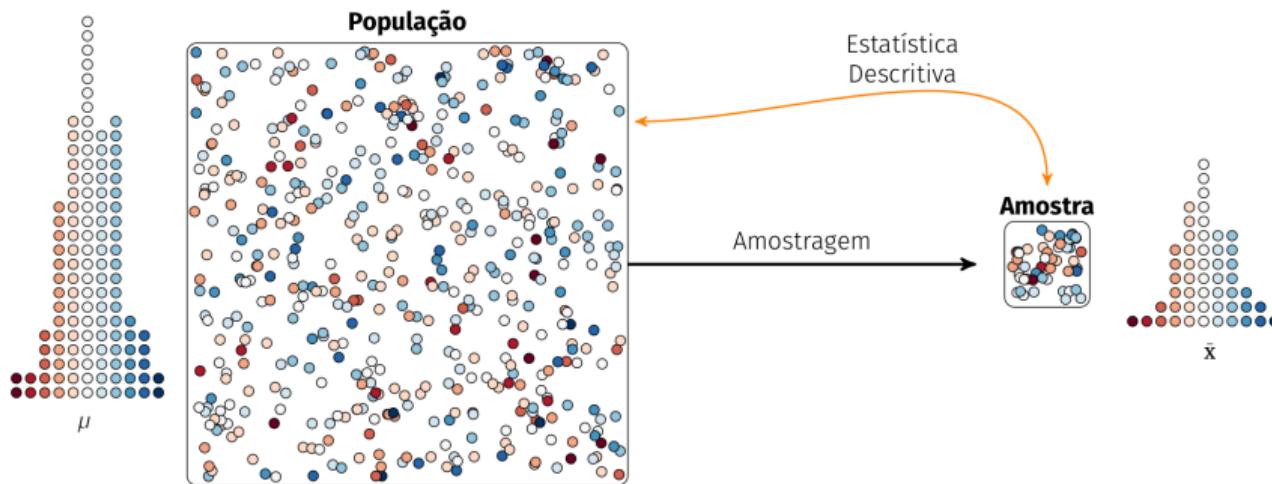
- A tabela abaixo refere-se ao número de acidentes no mês de janeiro. Encontre a média.



Número de acidentes	Frequência em dias
0	18
1	5
2	2
3	2
4	3
5	1
Total	31

$$\begin{aligned}\bar{x} &= \frac{18 \cdot 0 + 5 \cdot 1 + \dots + 3 \cdot 4 + 1 \cdot 5}{31} \\ &= 1.03\end{aligned}$$

# Média Aritmética



**Média populacional**

$$\mu = \frac{x_1 + x_2 + \dots + x_N}{N}$$

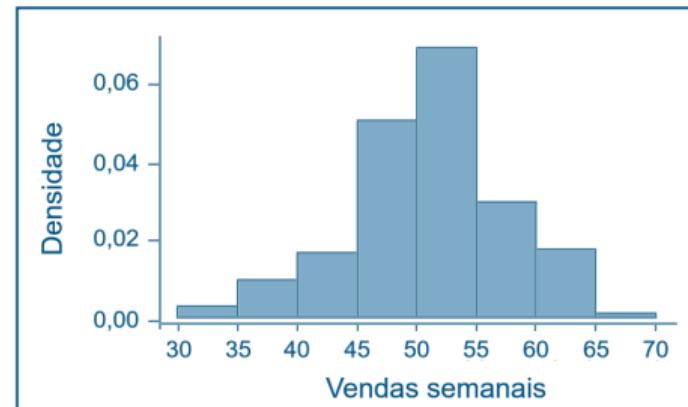
**Média amostral**

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

## Exemplo: vendas semanais

- Os dados representam as vendas semanais de vendedores de gêneros alimentícios:

Vendas semanais	Nº de vendedores
30 ← 35	2
35 ← 40	10
40 ← 45	18
45 ← 50	50
50 ← 55	70
55 ← 60	30
60 ← 65	18
65 ← 70	2



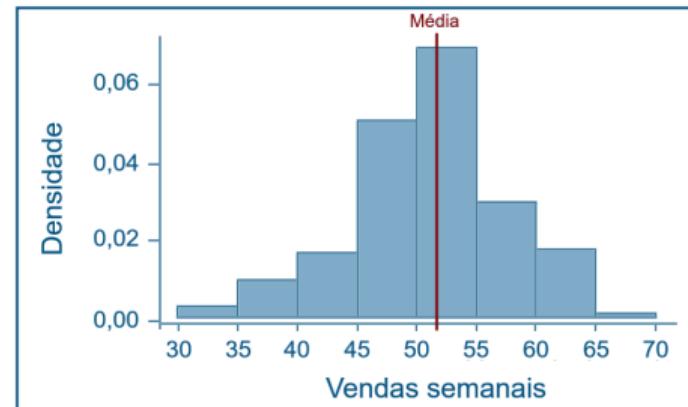
- Calcule a média da amostra,  $\bar{x}$ .

$$\bar{x} = \frac{(32.5) \cdot 2 + (37.5) \cdot 10 + \dots + (62.5) \cdot 18 + (67.5) \cdot 2}{200} = 51.2.$$

## Exemplo: vendas semanais

- Os dados representam as vendas semanais de vendedores de gêneros alimentícios:

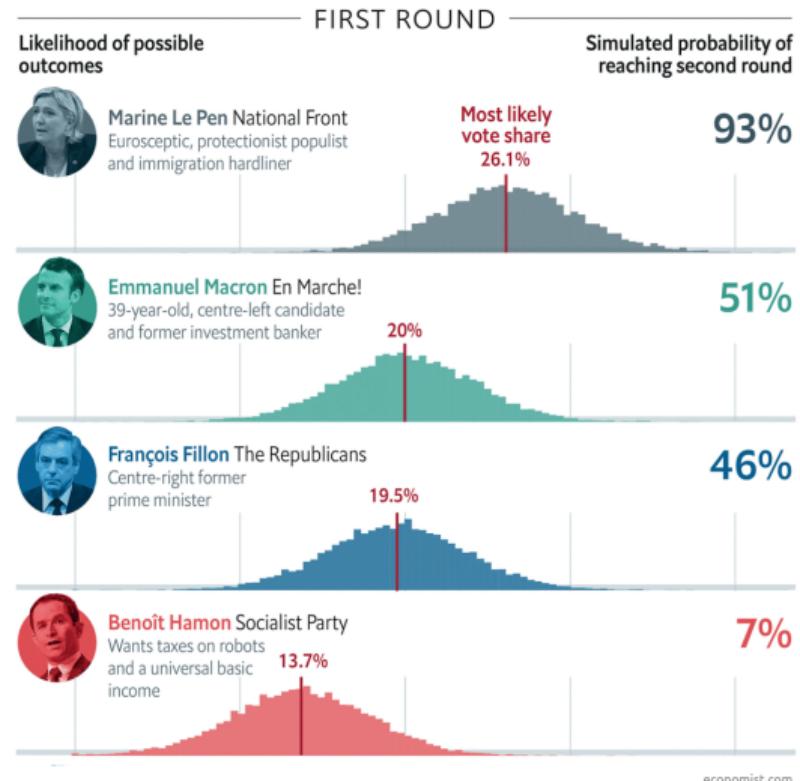
Vendas semanais	Nº de vendedores
30 - 35	2
35 - 40	10
40 - 45	18
45 - 50	50
50 - 55	70
55 - 60	30
60 - 65	18
65 - 70	2



- Calcule a média da amostra,  $\bar{x}$ .

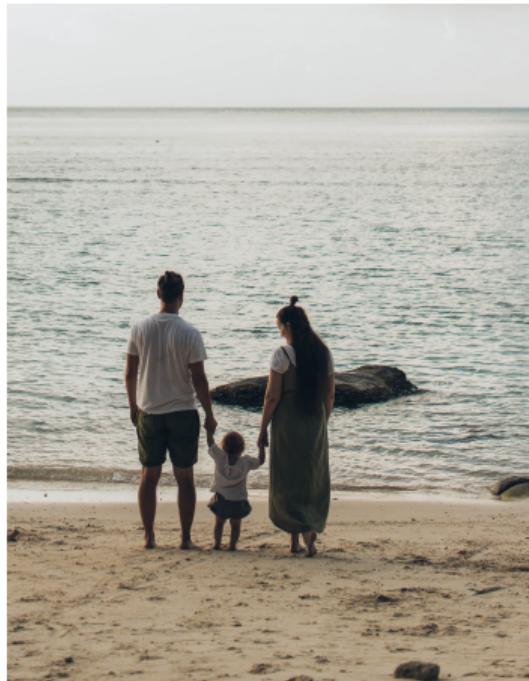
$$\bar{x} = \frac{(32.5) \cdot 2 + (37.5) \cdot 10 + \dots + (62.5) \cdot 18 + (67.5) \cdot 2}{200} = 51.2.$$

# Exemplo: eleição presidencial da França



## Exemplo: número de filhos

- ▶ Numa pesquisa realizada com 100 famílias, levantaram-se as seguintes informações:



Número de filhos	0	1	2	3	4	5	mais que 5
Frequência de famílias	17	20	28	19	7	4	5

1. Que problemas você enfrentaria para calcular a média? Faça alguma suposição e encontre-a.

Não temos um valor para “mais que 5”. Supondo o valor 6:

$$\bar{x} = \frac{0 \cdot 17 + 1 \cdot 20 + \dots + 5 \cdot 4 + 6 \cdot 5}{100} = 2,11$$

## Exemplo: número de erros de impressão

- Deseja-se estudar o número de erros de impressão em um livro. Para tanto, escolheu-se uma amostra de 50 páginas, obtendo-se o resultado:



Erros	Frequência
0	25
1	20
2	3
3	1
4	1

- Se o livro tem 500 páginas, qual o número de erros esperado no livro?

$$\begin{aligned}Me &= \frac{(0 \cdot 25 + 1 \cdot 20 + 2 \cdot 3 + 3 \cdot 1 + 4 \cdot 1)}{50} \\&= 0,66 \text{ erros/página}\end{aligned}$$

Assim, espera-se  $500 \times 0,66 = 330$  erros no livro.

# Mediana

## Mediana

- A mediana ( $M_d$ ) é o valor que ocupa a posição central da **série ordenada** de observações. Considere as observações ordenadas de forma crescente denotada por:

$$\underbrace{x_{(1)} \leq x_{(2)} \leq x_{(3)}}_{\text{1ª metade}} \leq x_{(4)} \leq \underbrace{x_{(5)} \leq x_{(6)} \leq x_{(7)}}_{\text{2ª metade}}$$

**Exemplo:** determine a mediana no conjunto de observações abaixo:

5 130 8 7 1 8 2 8 11

↓

$$\underbrace{1 \quad 2 \quad 5 \quad 7}_{1^{\text{a}} \text{ metade}} \quad 8 \quad \underbrace{8 \quad 8 \quad 11 \quad 130}_{2^{\text{a}} \text{ metade}}$$

Exemplo: cereais matinais

- Considere as quantidades de sódio (mg) em 20 cereais matinais. Encontre a mediana dos dados.



$$md = \frac{195 + 205}{2} \\ = 200$$



## Mediana

- A mediana ( $M_d$ ) é o valor que ocupa a posição central da **série ordenada** de observações. Considere as observações ordenadas de forma crescente denotada por:

$$\underbrace{x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq x_{(4)}}_{\text{1ª metade}} \leq \underbrace{x_{(5)} \leq x_{(6)} \leq x_{(7)} \leq x_{(8)}}_{\text{2ª metade}}$$

↓

$$md = \frac{x_{(4)} + x_{(5)}}{2}$$

- Note que a mediana pode ou não fazer parte dos dados observados!

## Exemplo: acidentes no mês de janeiro

- A tabela abaixo refere-se ao número de acidentes no mês de janeiro. Encontre a mediana.



Número de acidentes	Frequência em dias
0	18
1	5
2	2
3	2
4	3
5	1
Total	31

$$\begin{aligned} md &= x_{(16)} \\ &= 0 \end{aligned}$$

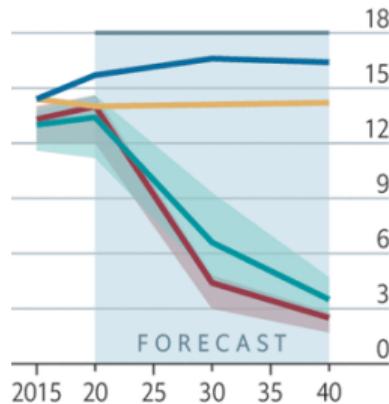
# Exemplo: meta de redução na emissão de gases

## Fatal extraction

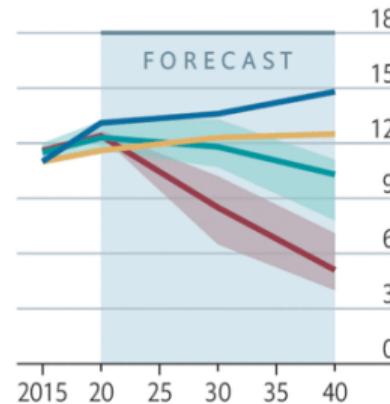
Forecast global CO<sub>2</sub> emissions from fossil fuels, gigatonnes per year

— Implied by countries' fossil-fuel production plans      — Implied by emissions reduction pledges      — Needed to limit global warming to 2°C      — Needed to limit global warming to 1.5°C

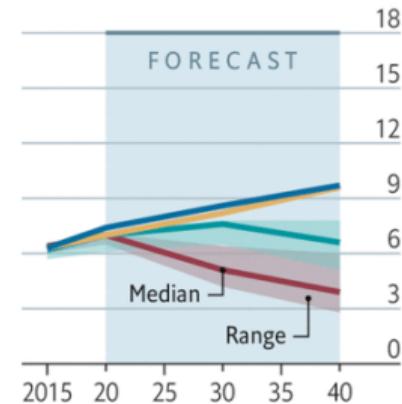
### Coal



### Oil



### Gas

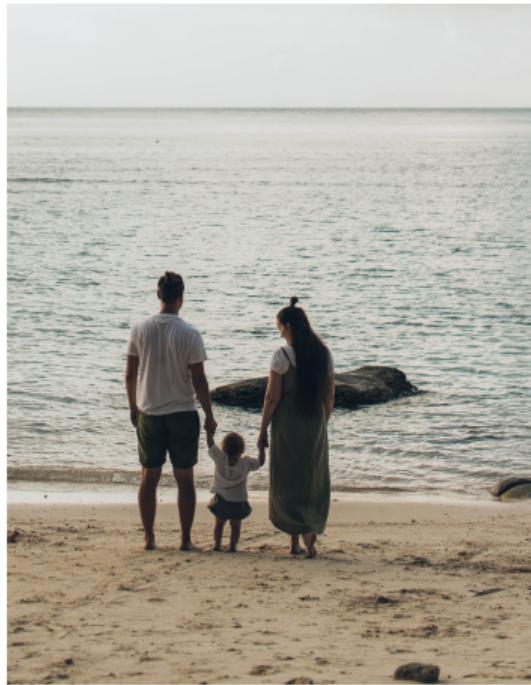


Source: "The Production Gap" by SEI, IISD, ODI, Climate Analytics, CICERO and UNEP, 2019

The Economist

## Exemplo: número de filhos

- ▶ Numa pesquisa realizada com 100 famílias, levantaram-se as seguintes informações:



Número de filhos	0	1	2	3	4	5	mais que 5
Frequência de famílias	17	20	28	19	7	4	5

- ▶ Qual a mediana do número de filhos?

Como temos  $\underbrace{0 \ 0 \ \dots \ 0}_{17\times} \ \underbrace{1 \ 1 \ \dots \ 1}_{20\times} \ \underbrace{2 \ 2 \ \dots \ 2}_{28\times}$ .

Então,  $md = 2$ .

# Moda

# O que seria “estar na moda”?

---

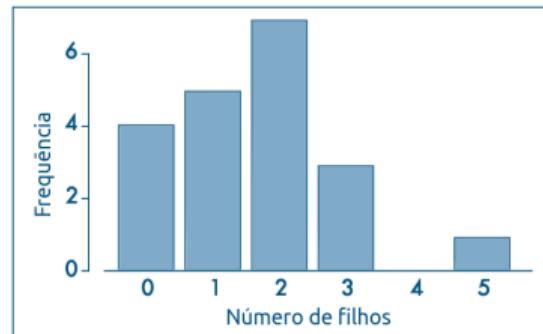


# Moda

- A moda ( $Mo$ ) é o valor que apresenta a maior freqüência da variável entre os valores observados;

Nº de filhos	Frequência
$x_i$	$n_i$
0	4
1	5
2	7
3	3
5	1
Total	20

Figura: Gráfico de barras para a variável: número de filhos.



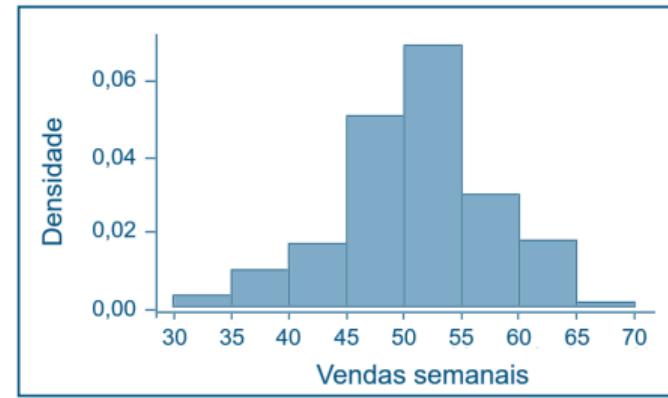
Fonte: Estatística Básica (Bussab e Morettin, 2017)

- Para o caso de valores individuais, a moda pode ser determinada imediatamente observando-se a freqüência absoluta dos dados.

## Exemplo: vendas semanais

- Os dados representam as vendas semanais de vendedores de gêneros alimentícios:

Vendas semanais	Nº de vendedores
30 ⊜ 35	2
35 ⊜ 40	10
40 ⊜ 45	18
45 ⊜ 50	50
50 ⊜ 55	70
55 ⊜ 60	30
60 ⊜ 65	18
65 ⊜ 70	2



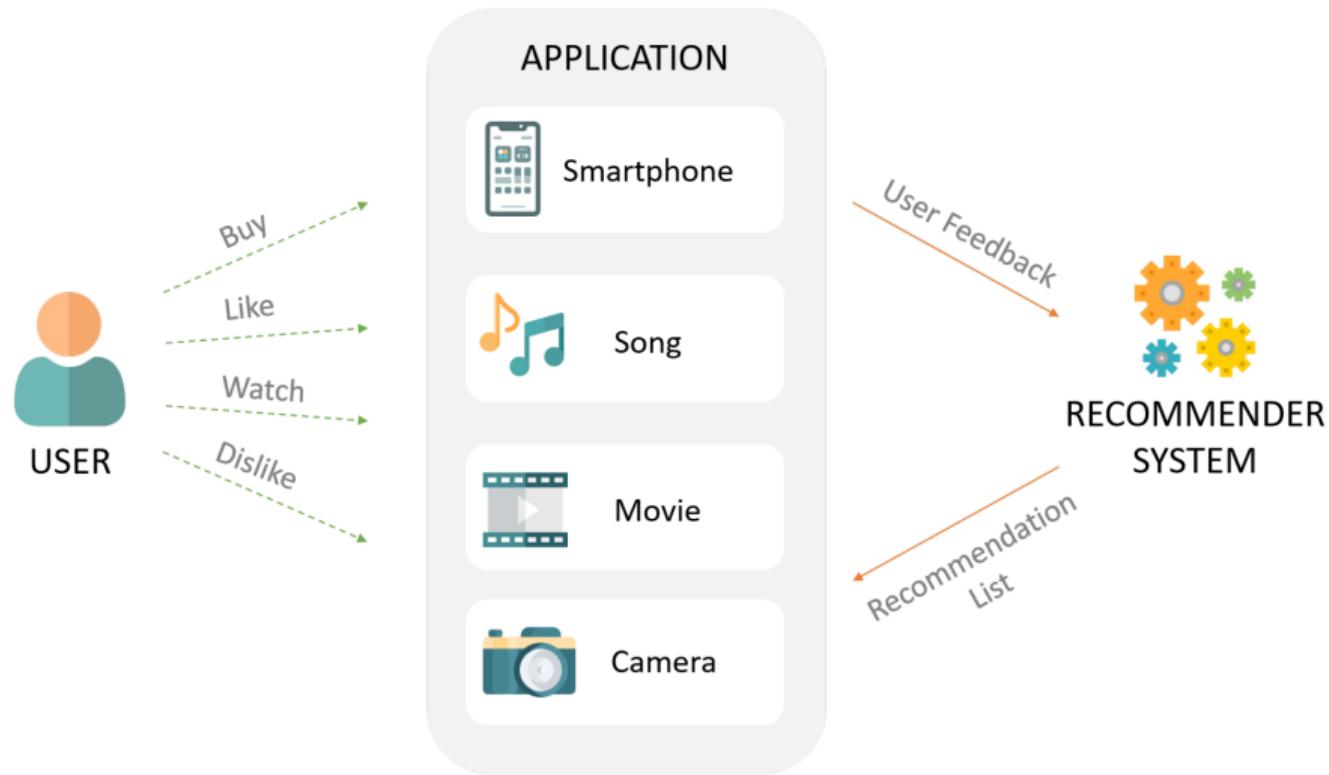
## Exemplo: acidentes no mês de janeiro

- A tabela abaixo refere-se ao número de acidentes no mês de janeiro.



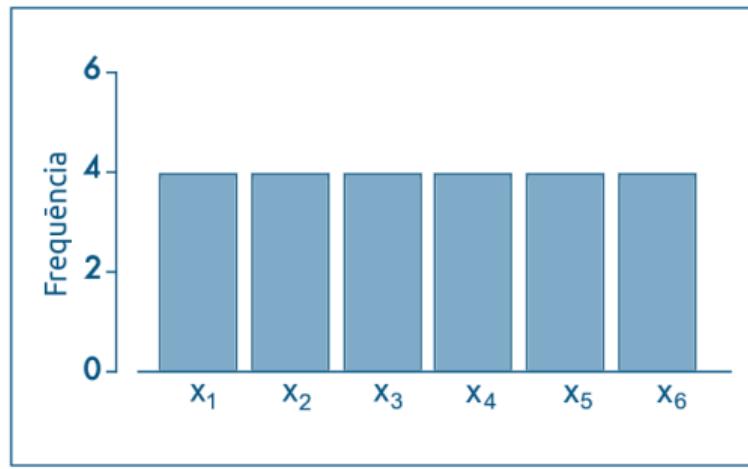
Número de acidentes	Frequência em dias
0	18
1	5
2	2
3	2
4	3
5	1
Total	31

# Cold start problem



# Distribuição amodal

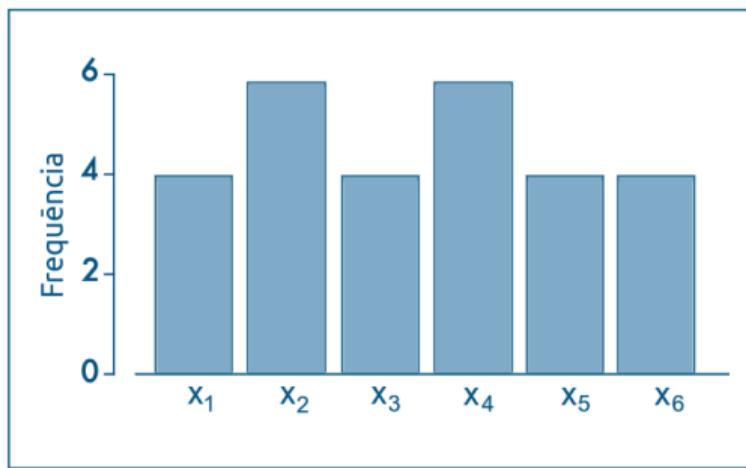
- Um conjunto de dados pode apresentar todos seus elementos com a mesma freqüência absoluta;



- Neste caso não existirá um valor modal, e a distribuição será classificada como **amodal**;

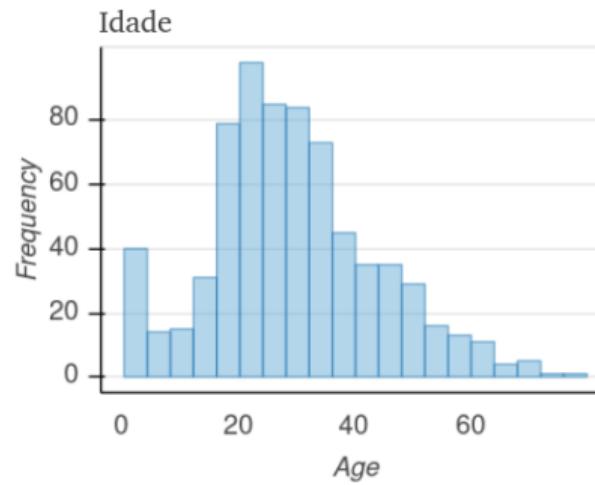
# Distribuição plurimodal

- Há casos em que a seqüência de observações apresenta vários elementos com freqüência iguais, implicando numa **distribuição plurimodal**.



# Exemplo: investigando o naufrágio do Titanic

Distinct Count	88
Unique (%)	12.3%
Missing	177
Missing (%)	19.9%
Infinite	0
Infinite (%)	0.0%
Memory Size	11.2 KB
Mean	29.6991
Minimum	0.42
Maximum	80
Zeros	0
Zeros (%)	0.0%



# Referências

- Bussab, WO; Morettin, PA. Estatística Básica. São Paulo: Editora Saraiva, 2006 (5<sup>a</sup> Edição).
- Magalhães, MN; Lima, ACP. Noções de Probabilidade e Estatística. São Paulo: EDUSP, 2008.

